Spider

Armitano Joshua, Ballario Marco,
Garro Christian, Gastaldi Paolo,
Giraudo Roberto, Mullace Matteo,
Olivero Emanuele

Obiettivo

Realizzare uno spider che:

- conta le hit di determinati professori su internet
- realizza una classifica dei professori più citati sul web

Tecnologie utilizzate

- LAMPP
- Python
- Scrapy
- Bootstrap

Parti principali

- Interfaccia utente
- Lancio degli spider
- Ricerca
- Database

Database

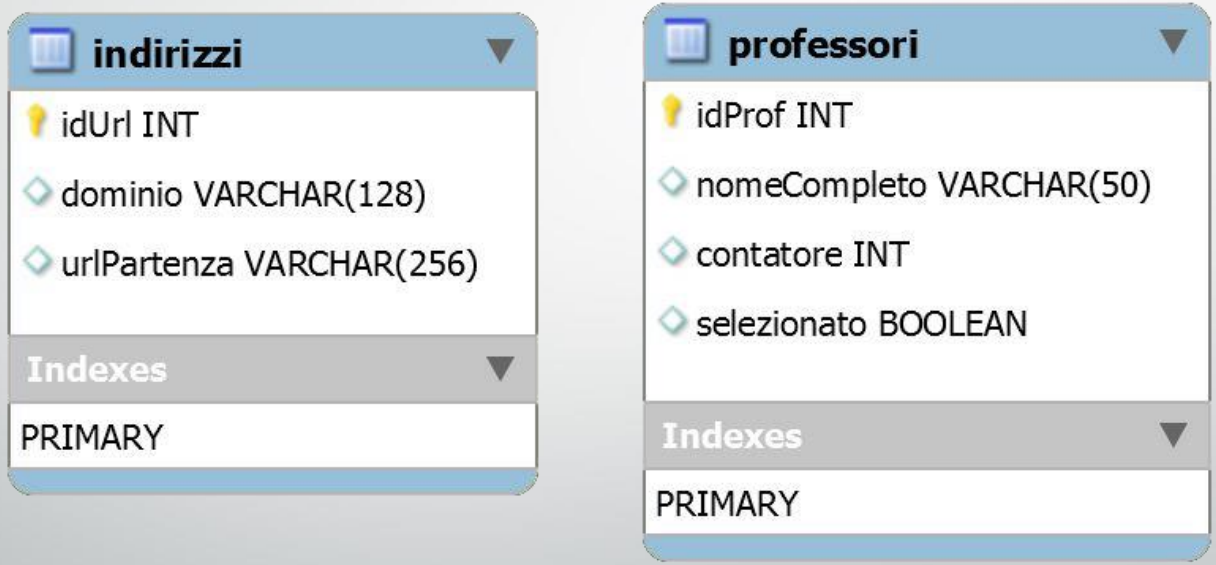
indirizzi
idUrl INT
dominio VARCHAR(128)
urlPartenza VARCHAR(256)
Indexes
PRIMARY
professori
idProf INT
nomeCompleto VARCHAR(50)
contatore INT
selezionato BOOLEAN
Indexes
PRIMARY

GestioneDatabase.py

Classe Python manager del database.

Permette il dialogo in lettura e scrittura con la base di dati del progetto.

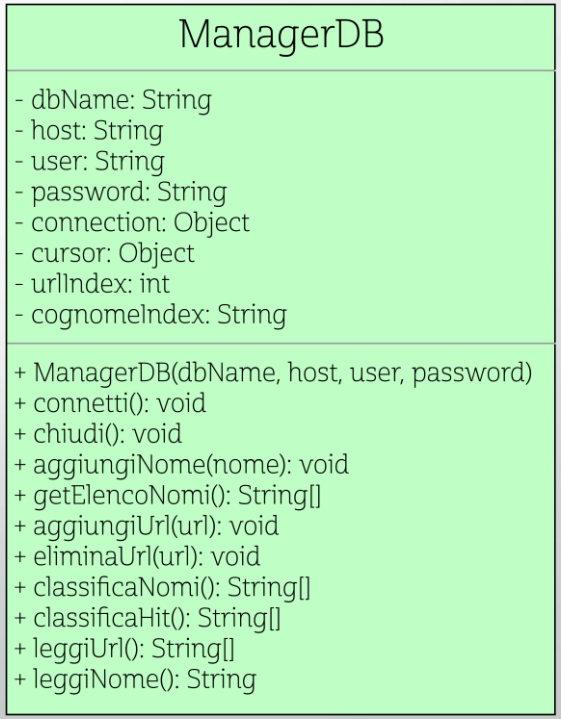

aggiungiNome(self, nomi)

```
# Metodo per l'aggiunta di un risultato al db. Controlla la presenza di un nome e in caso
# affermativo ne va a incrementare il contatore. Gestisce anche array di nomi completi.
def aggiungiNome(self, nomi):
    try:
        self.__cursor = self.__connessione.cursor()
        self.__cursor.execute('SELECT nomeCompleto FROM professori ORDER BY nomeCompleto') #ricava tutti i nomi completi
        items = self.__cursor.fetchall()

        for singoloNome in nomi:
            for item in items: #scorre tutti i nomi completi in cerca di riscontri
                if item[0].lower() == singoloNome.lower():
                    self.__cursor.execute("UPDATE professori SET contatore = contatore + 1 WHERE nomeCompleto=\'%s\'" % (singoloNome))
            self.__connessione.commit()

    except MySQLdb.Error, e:
        print "Error %d: %s" % (e.args[0],e.args[1])
        #exit(3)
```

Scrapy

Scrapy è un framework Python di web crawling libero e open source.

È utilizzato per il web scraping, per estrarre dati utilizzando le API o come web crawler.

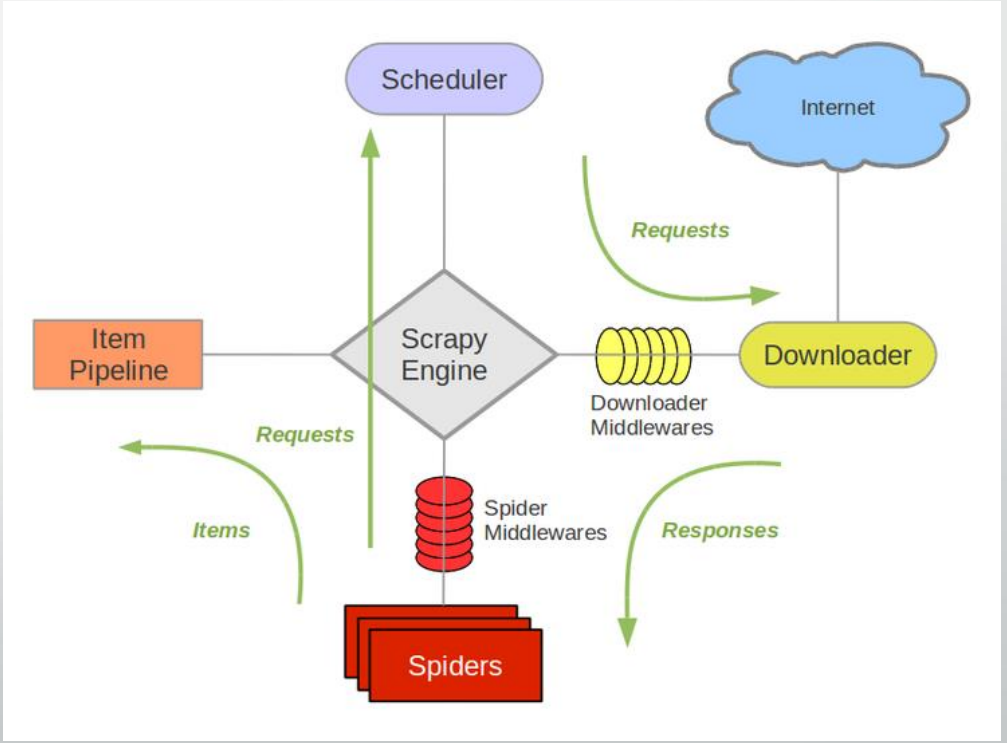

XPath

XPath è un linguaggio, parte della famiglia XML, che permette di individuare i nodi all'interno di un documento XML.

Le espressioni XPath, a differenza delle espressioni XML, non identificano la struttura di un documento, ma ne localizzano con precisione i nodi.

MySpider.py

Classe fondamentale con il compito di:

- Scaricare pagine web
- Estrarre contenuti da elaborare

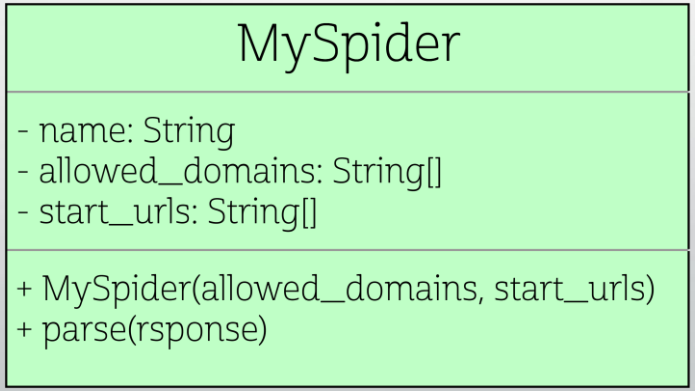

MySpider.py

```
from scrapy.spiders import Spider
from scrapy.selector import Selector
from items import ElementoDaEsaminare

class MySpider(Spider):
        name = "spiderRicerca"
        allowed_domains = []
        start_urls = []

        def __init__(self, allowed_domain, start_url):
                self.allowed_domains.append(allowed_domain)
                self.start_urls.append(start_url)

                print "Spider> analizzando " + allowed_domain + "..."

        def parse(self, response):
                analizzatorePagina = Selector(response)
                paginaSito = ElementoDaEsaminare()
                paginaSito['body'] = analizzatorePagina.xpath('//body//text()').extract() #estrae tutto il corpo della pagina

                print "Spider> pagine ricevute"
                return paginaSito
```

pipelines.py

```
class SpiderPipeline(object):
        def process_item(self, item, spider):
                gestoreDatabase = ManagerDB() #vedi altra feature
                gestoreDatabase.connetti()

                print "Spider> processando le pagine..."

                elencoProfessori = gestoreDatabase.getElencoCognomi()

                for prof in elencoProfessori:
                        print "Spider> ricercando " + prof

                #item['body'] = [element.lower() for element in item['body']] #tutti gli elementi in minuscolo
                corpoPagina = ''.join(item['body']) #dalla lista ottengo un array
                corpoPagina.lower() #stringa tutta in minuscolo

                for professore in elencoProfessori:
                        if corpoPagina.find(professore.lower()) >= 0 : #find() restituisce l'indice dell'occorrenza nella stringa):

                                print "Spider> trovato " + professore
                                gestoreDatabase.aggiungiCognome([professore]) #vedi altra feature
                #raise DropItem("Elemento non piu' utile") #eliminazione dell'item (non obbligatoria) (lancia un'eccezione, pertanto non e' stata abilitata)

                gestoreDatabase.chiudi()
```

Avvio degli spider

Fasi da eseguire:

1. Tenere traccia dei professori selezionati
2. Aggiornare il database
3. Avviare il gestore degli spider
4. Visualizzare la classifica

Avvio degli spider

-diagramma soluzione-

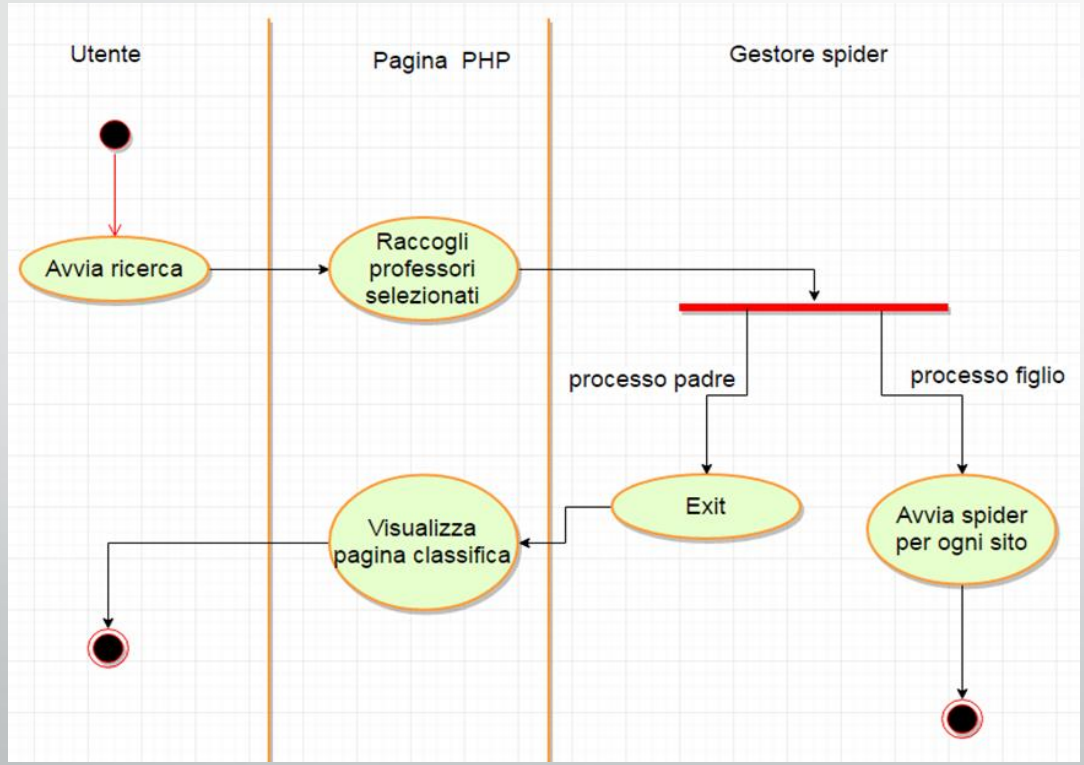

Creazione di un processo zombie

avviaSpider.php

```php
/*connessione*/
$dbh = new PDO("mysql:host=$hostname;dbname=$database_name", $username, $password);

/*deselezione di tutti i campi*/
$stmt = $dbh->prepare('UPDATE professori SET selezionato=FALSE, contatore=0'); /*stmt = statement*/
$stmt->execute();

/*seleziono solo i prof che sono stati selezionati dell'utente*/
foreach($_GET['elencoProfSelezionati'] as $professore){ //elencoProfSelezionati è un array contenente le checkbox selezionate
    $stmt->closeCursor();
    $stmt = $dbh->prepare('UPDATE professori SET selezionato=TRUE WHERE idProf=:idProf'); //stmt = statement
    $stmt->bindParam(':idProf', $professore, PDO::PARAM_INT);
    $stmt->execute();
}

$cmd = escapeshellcmd('python ' .__DIR__ .'/gestoreSpider.py');
echo "cmd: $cmd <br>";
echo shell_exec($cmd);

/*disconnessione*/
$dbh = null;

/*redirecting alla pagina dei risultati*/
header("Location: classifica.php");
die();
```

gestoreSpider.py

```
#questo crea un processo zombie, ma almeno il
#processo chiamante (la pagina php) può andare avanti
if os.fork() > 0:
    print "Ricerca avviata"
    sys.exit(0)
```

```
#creazione del gestore del database
managerDB = ManagerDB()
managerDB.connetti()

#lista dei siti su cui avviare gli spider
websites = managerDB.leggiUrl()

# crawlers in esecuzione
crawlers = []
crawlersCompletati = 0;
```

```
#funzione per gestire l'evento sulla chiusura dello spider
def spider_closing(spider):
    crawlersCompletati = crawlersCompletati+1

    #se hanno completato tutti i gli esecutori degli spider chiudo il programma
    if crawlersCompletati == len(websites):
        print "finito"
        bloccaProcesso.stop()

#per ogni sito lancio uno spider tramite un suo esecutore
for i in range(len(websites)):
    # crawl responsibly
    #settings.set("USER_AGENT", "Kiran Koduru (+http://kirankoduru.github.io)")

    #imposto le impostazioni
    setting = get_project_settings()
    setting.setmodule(settings, 300)

    #creo un nuovo esecutore di uno spider
    crawler = Crawler(MySpider, setting)

    crawlers.append(crawler)

    #aggiungo all'esecutore dello spider una funzione sull'evento di chiusura dello spider
    crawler.signals.connect(spider_closing, signal=signals.spider_closed)

    #avvio dello spider passando gli appositi parametri
    crawler.crawl(websites[i][0], websites[i][1])

#per bloccare il processo, altrimenti terminerebbe prima dei crawler
bloccaProcesso.run()
```

Interfaccia utente

Tre pagine principali:

1. index.php
2. classifica.php
3. link.php

Index.php

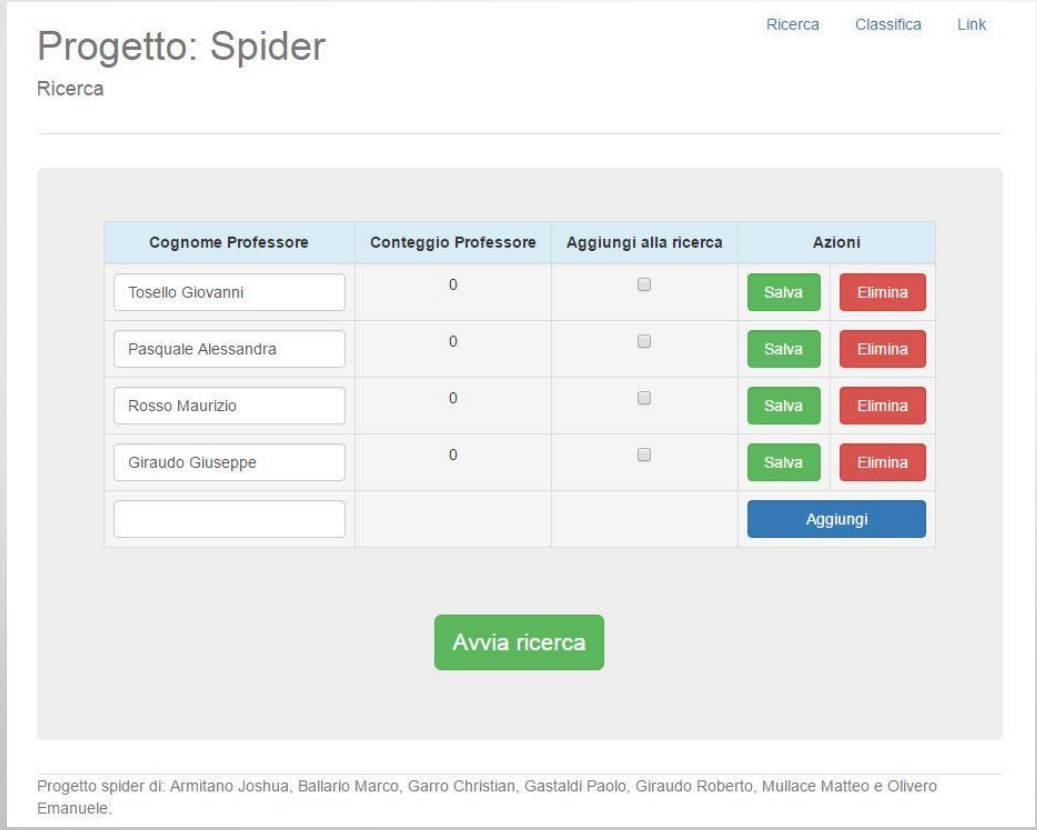
Ricerca
Classifica
Link
Progetto: Spider
Ricerca
Cognome Professore
Conteggio Professore
Aggiungi alla ricerca
Azioni
Tosello Giovanni
0
Salva
Elimina
Pasquale Alessandra
0
Salva
Elimina
Rosso Maurizio
0
Salva
Elimina
Giraudo Giuseppe
0
Salva
Elimina
Aggiungi
Avvia ricerca
Progetto spider di: Armitano Joshua, Ballario Marco, Garro Christian, Gastaldi Paolo, Giraudo Roberto, Mullace Matteo e Olivero Emanuele.

Classifica.php

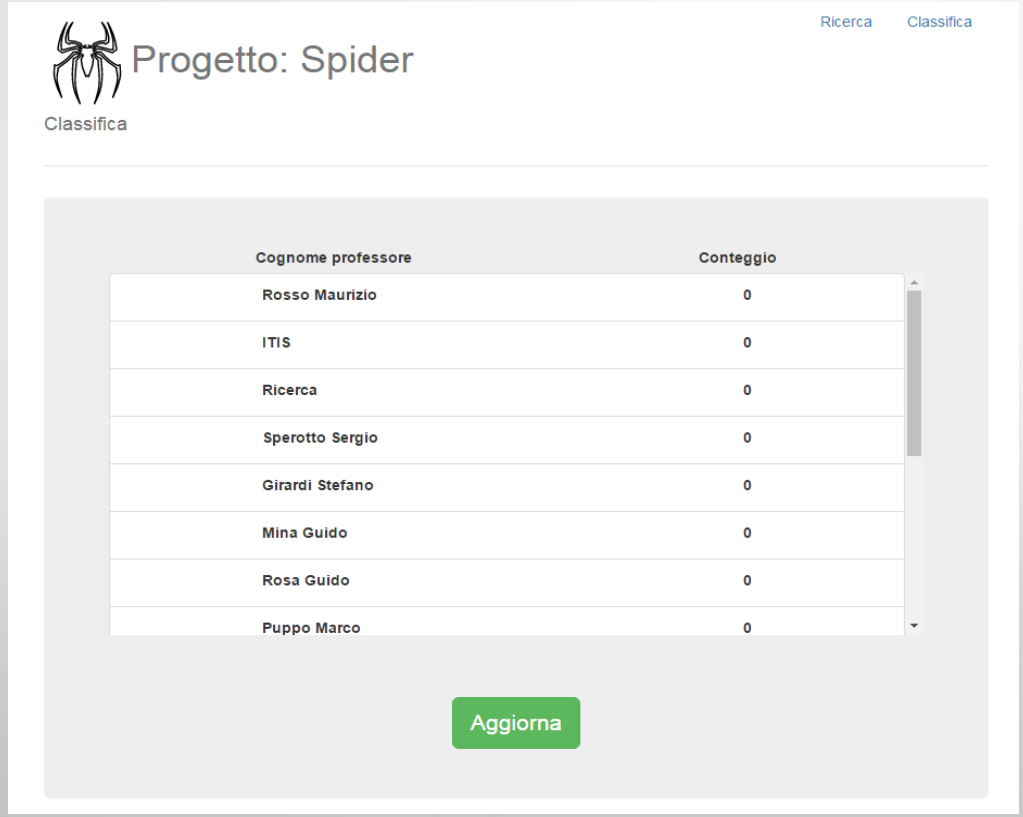

Link.php

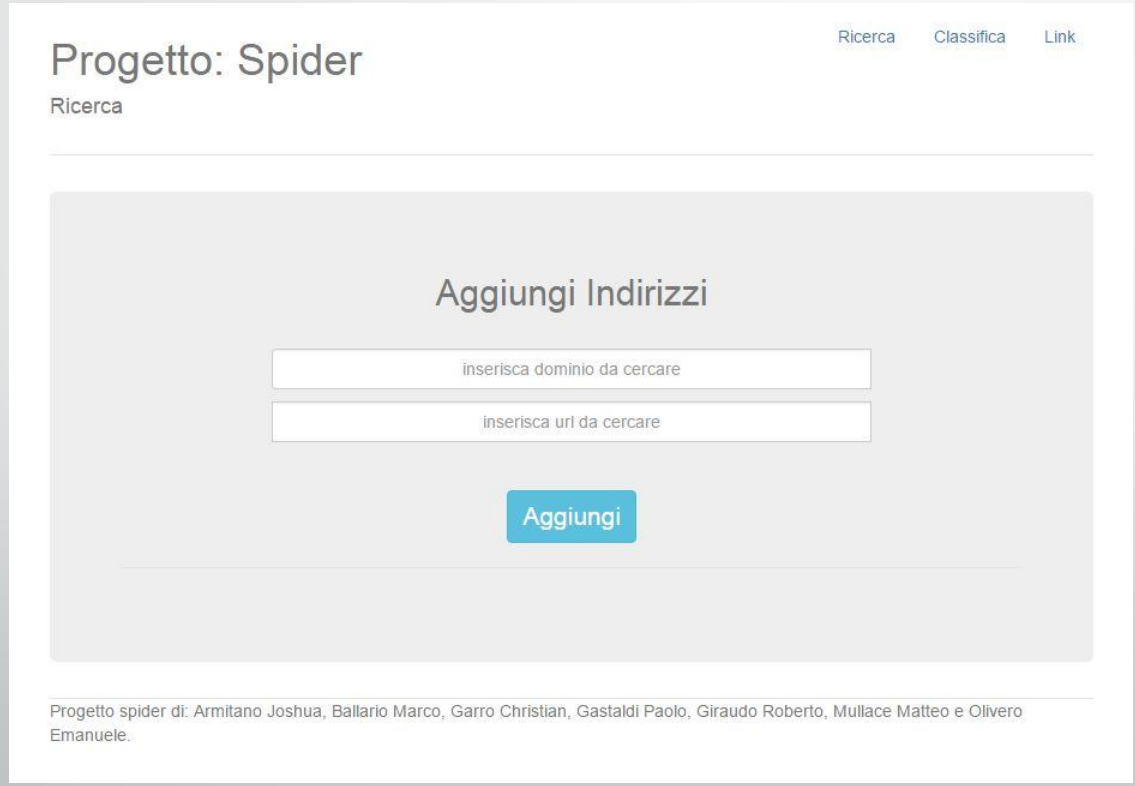
Ricerca
Classifica
Link
Progetto: Spider
Ricerca
Aggiungi Indirizzi
inserisca dominio da cercare
inserisca url da cercare
Aggiungi
Progetto spider di: Armitano Joshua, Ballario Marco, Garro Christian, Gastaldi Paolo, Giraudo Roberto, Mullace Matteo e Olivero Emanuele.

Repository ufficiale

https://github.com/Onhyro/spider.git